

基于用户评测数据构造用户满意度的有监督学习建模

传统的点击数据如下：

$$\{(x_i, y_i)\}_{i=1}^n$$

传统格式这种，可以用 pointwise, pairwise, listwise。选择哪一种主要适 y_i 的格式来定。

新的评测数据如下：

$$\{x_i^1, x_i^2, \dots, x_i^m, y_i\}$$

其中 m 为参与评测的一个 query 下 doc 的个数， y_i 是对本次排序的一个反馈。 y_i 的取值有五档，5,4,3,2,1。

基于上述评测数据有下面两种数据的使用方法。

1：若是只对 5 中的样本进行学习。

5 意味着本次的排序是非常合适的。然后可以按照位次生成新的 Label。按照如下的规则来生成 Label。

$$Label = \begin{cases} 5, position = 1 \\ 4, position = 2, 3 \\ 3, position = 4, 5 \\ 2, position \leq 10 \\ 1, position \leq 20 \\ 0, others \end{cases}$$

因为只有 5 完全满意才能保证排在前面的一定大概率优化后者，故可以做次假设。但是这样一来不能有效的利用那些排序结果不好的样本，其实这些样本作用更大。

2：对全部样本进行利用

不同位次的排序对于最终体验（5,4,3,2,1）的影响是不同的。第一条没排好和第 10 条没排好效果是不一样的。

所以关键一个步骤在于得到位次的权重。

这里提供一个按照曝光条数来的权重方案。统计每个位次的曝光条数。

假定第一个位置的曝光比例为 1。后面的位次的曝光比例按照曝光位次之比得到。

如此得到评测用的 m 条的曝光比例，记为 $\{w_1, \dots, w_m\}$ 。作为归一化后得到的权重值仍然记为 $\{w_1, \dots, w_m\}$, $\sum w_i = 1$

记需要学习的 ranker 为 f 。

我们可以得到整个排序最后的总分为 $\sum w_i f(x_i^1)$ 。

下面我们对 $\sum w_i f(x_i^1)$ 进行分析。

3：TS = $\sum w_i f(x_i^1)$ 分析

即一次排序的顺序为 $\pi = (\pi_1, \dots, \pi_m)$ ，其得分分别为 $F = (f_{\pi_1}, \dots, f_{\pi_m})$ 。

TS = $\sum w_i f_{\pi_i}$ 。

3.1：问 TS 何时可以取得最大值。当时是 $F = (f_{\pi_1}, \dots, f_{\pi_m})$ 满足 $f_{\pi_i} \geq f_{\pi_j}$, if $i \leq j$

证明比较简单，这里先不展开了。

3.2: $TS \leq 1$

由性质 1 和 2 可知，当我们的打分函数给定后，按照打分出来的最大值降次排序，能够得到最好的 TS 值。

这里我们将 TS 记为满意度度量指标。

4: 利用 TS 求解 Ranker。

$$L(f, X, Y) = \min_f \|5TS - Y\|_F = \min_f \sum_{q=1}^Q \left\| \sum \mathbf{w}_i f(x_i, \theta) - Y_q \right\|_F$$

若 $f(x_i, \theta) = \theta^T x_i$

$$\min_f \sum_{q=1}^Q \left\| \sum \theta^T \mathbf{w}_i x_i - Y_q \right\|_F = \min_f \sum_{q=1}^Q \left\| \theta^T \sum \mathbf{w}_i x_i - Y_q \right\|_F$$

记一个 query 下所有召回的 doc 的第 j 维特征为 $(\sum \mathbf{w}_i x_i)_j$ 。

$$\sum \mathbf{w}_i x_i = \left[\left(\sum \mathbf{w}_i x_i \right)_1, \dots, \left(\sum \mathbf{w}_i x_i \right)_n \right]^T = [\mathbf{t}_1, \dots, \mathbf{t}_n]^T$$

$$\text{则 } \min_f \sum_{q=1}^Q \left\| \theta^T \sum \mathbf{w}_i x_i - Y_q \right\|_F = \|\theta^T T - Y\|_F$$

其中 $T \in \mathbb{R}^{n \times m}$, n 为特征个数, m 为样本的个数。

对 θ 进行求导即可得 θ 的显示解。

$$(\theta^T T - Y) T^T = 0$$

$$\text{可得 } \theta = \text{inv}(T T^T)^T T Y^T \in \mathbb{R}^n$$

若 $f(x_i, \theta)$ 是网络结构，也可以进行求导，利用求导的链式法则。

若 $f(x_i, \theta)$ 是 GBDT 结构，需要在进行推导，目前还没想到求解的思路，打算去看看 pairwise 的形式，看能不能有启发。